

MSPR — Bloc 3

Analyse Prédictive des Tendances Électorales

Région Bretagne — Preuve de Concept

Sommaire

Préparation

- Contexte & Objectifs
- Validation qualité des données
- Comparaison nationale vs Bretagne
- Zone géographique
- Données collectées

Architecture

- Architecture Data
- Technologies utilisées
- Pipeline ETL
- Modèle de données

Analyse & IA

- Analyse exploratoire (EDA)
- Matrice de corrélation
- Modèles testés
- Résultats & Accuracy

Conclusion

- Recommandations stratégiques
- Répartition du travail
- Conclusion

Contexte & Objectifs

Pourquoi ce projet ? Quelle mission ?

Contexte

Electio-Analytics est une start-up spécialisée dans le conseil stratégique électoral. Elle souhaite valider la faisabilité d'un modèle prédictif basé sur des données socio-économiques publiques.

Problématique

Dans quelle mesure les indicateurs socio-économiques permettent-ils d'anticiper les tendances électorales régionales à moyen terme ?

Périmètre

Preuve de Concept sur la région Bretagne — données publiques open source.

Objectifs du projet

- ① Collecter & structurer les données publiques
- ② Mettre en place un pipeline ETL automatisé
- ③ Construire un entrepôt décisionnel
- ④ Développer un modèle prédictif
- ⑤ Restituer via tableaux de bord interactifs

Zone Géographique : La Bretagne

Choix justifié par des critères techniques et analytiques

3,4M

habitants

4

départements

1 200+

communes

100%

Open Data disponible

Disponibilité des données

Sources ouvertes : INSEE, data.gouv.fr, Ministère de l'Intérieur.
Données électorales, emploi, démographie, sécurité etc.

Taille idéale pour un POC

Volume maîtrisable pour une première expérimentation, avec suffisamment de données pour entraîner un modèle robuste.


Diversité socio-économique

Rennes/Brest (urbain) vs zones rurales : contrastes électoraux mesurables — agriculture, agroalimentaire, numérique.

Richesse politique



Tradition de vote modéré, variations scrutin-à-scrutin, montée de partis récents : terrain idéal pour tester le modèle.

Comparaison élections nationales vs Bretagne




Architecture Data

Du fichier brut au tableau de bord décisionnel



Technologies utilisées



Données Collectées

Sources publiques fiables — formats CSV, JSON, XLSX

Résultats électoraux

Source : datagouv.fr

Format : CSV

Données démographiques

Source : INSEE

Format : CSV/API

Emploi & chômage

Source : INSEE / Pôle Emploi

Format : CSV

Pauvreté & revenus

Source : INSEE

Format : CSV

Criminalité & sécurité

Source : data.gouv.fr

Format : CSV

Entreprises

Source : SIRENE / INSEE

Format : CSV

Pipeline ETL/ workflow d'automatisation

Extract → Transform → Load

E EXTRACT

- Téléchargement CSV/API
- Formats : CSV, XLSX
- Sources : INSEE, data.gouv.fr



T TRANSFORM

- Suppression doublons
- Gestion valeurs manquantes
- Jointure sur code INSEE (referential de données)
- Normalisation & enrichissement




L LOAD


- Chargement PostgreSQL
- Schéma en étoile
- Contrôle qualité SQL

VALIDATION DE LA QUALITE DE LA DONNEE

AVANT NETOYAGE




APRES NETOYAGE



KPI	Avant nettoyage	Après nettoyage
Complétude	99,22 %	100 %
Valeurs invalides	0,78 %	0 %
Valeurs uniques	270	96
Doublons	Présents	Supprimés
Cohérence départementale	Non	Oui

Modèle de Données — Schéma en Étoile



```
INSERT 0 2
dwh=# SELECT * FROM dim_temps;
      annee
-----
      2012
      2017
(2 rows)

dwh=#
```

```
dwh=# \d dim_candidat
dwh=# INSERT INTO dim_candidat (famille_politique)
SELECT DISTINCT famille_politique
FROM staging_resultats;
INSERT 0 5
dwh=# SELECT * FROM dim_candidat;
      famille_politique
-----
      Droite
      Autre
      Gauche
      Extreme_Droite
      Centre
(5 rows)

dwh=#
```

```
code_insee | code_departement | code_commune | nom_commune
-----
22001      | 22                | 001          | allineuc
22002      | 22                | 002          | andel
22003      | 22                | 003          | aucaleuc
22004      | 22                | 004          | begard
22005      | 22                | 005          | belle-isle-en-ter
22006      | 22                | 006          | berhet
22007      | 22                | 007          | binic
22008      | 22                | 008          | bobital
22009      | 22                | 009          | le bodeo
22011      | 22                | 011          | boqueho
(10 rows)


[END]
```

```
Schema | Type | Owner
-----
public | FLOWETL_doc1_copy
      | table | admin
public | FLOWETL_mm
      | table | admin
public | FLOWETL_resultat_bretagne_2017_joined_prepared_prepared_
stacked | table | admin
public | dim_candidat
      | table | admin
public | dim_socio
      | table | admin
public | dim_temps
      | table | admin
public | dim_zone
      | table | admin
public | fact_resultats
      | table | admin
public | staging_resultats
      | table | admin
(9 rows)



[END]
```

Analyse Exploratoire Des Données (EDA)

Comprendre les données avant de modéliser



Explorons rapidement les relations clés entre variables pour mieux comprendre les tendances avant la modélisation.



Matrice de corrélation

▼ Matrice de corrélation sur 6 variables (Pearson) Pas de partage ▼



abstentions...	1 000	0,009	-0,004	-0,052	0,037	0,047
% score fam...	0,009	1 000	0,250	-0,220	-0,817	-0,232
taux_chom...	-0,004	0,250	1 000	0,424	-0,580	-0,814
taux_pauvr...	-0,052	-0,220	0,424	1 000	-0,146	-0,767
revenu_mé...	0,037	-0,817	-0,580	-0,146	1 000	0,624
nbre_entre...	0,047	-0,232	-0,814	-0,767	0,624	1 000
	abstentions_max	% score famille politi...	taux_chomage	taux_pauvrete	revenu_médian	nbre_entreprise

Modèles Testés

Apprentissage supervisé — comparaison multi-algorithmes

Arbre de Décision

74,1%

ROC AUC

✓ Simple, interprétable

Random Forest

75,3%

ROC AUC

✓ Visualisable,
bonne précision

Regression linéaire

75,6%

ROC AUC


✓ Très bonne précision,

✓ MODÈLE RETENU

Résultats & Accuracy

Regression linéaire — 75,6% ROC AUC

Comparaison des modèles



Métriques — Regression linéaire

F1-Score

37,90%

Recall

45,20%

precision

46%

Accuracy

75,6%

Recommandations Stratégiques

Apports métier et perspectives de déploiement

01 Déployer le modèle en production

Industrialiser le pipeline ETL et le modèle Regression linéaire sur un serveur dédié avec rafraîchissement automatique des données.

02 Étendre à d'autres régions

La méthodologie est reproductible. Prochaine étape : Pays de la Loire ou Normandie pour enrichir la base de comparaison.

03 Enrichir les indicateurs

Intégrer des données de mobilité, de logement social et de dépenses publiques pour affiner la précision du modèle.

04 Tableau de bord Power BI interactif

Livrer aux clients une interface permettant de simuler des scénarios et d'explorer les projections zone par zone.

Répartition du Travail — Équipe 4

Organisation et contributions individuelles

Personne 1 — Collecte & ETL

Extraction des données open data
Nettoyage & normalisation
Pipeline Python automatisé

Personne 2 — Base & MCD

Modélisation conceptuelle
Création PostgreSQL
Schéma en étoile

Personne 3 — ML & Accuracy

Analyse exploratoire (EDA)
Modèles supervisés
Évaluation & métriques

Personne 4 — Viz & Slides

Tableaux de bord Power BI
KPI décisionnels
Support de soutenance

Merci pour votre attention

Ce projet démontre la faisabilité d'une architecture décisionnelle complète pour l'analyse prédictive électorale.

Pipeline ETL :

Automatisation documenté

Entrepôt SQL :

Schéma en étoile — PostgreSQL

Modèle ML :

Regression linéaire — 75,5 % ROC AUC

Dashboards :

dataiku — vues décisionnelles

Questions ?