

# MSPR – Big Data GROUPE 4

Mise en Situation Professionnelle Reconstituée

## Analyse Prédicative des Tendances Électorales

|                      |                                                 |
|----------------------|-------------------------------------------------|
| Établissement        | EPSI Paris                                      |
| Formation            | Master 1 Ingénierie Informatique                |
| Unité d'enseignement | Big Data & Intelligence Artificielle            |
| Type de document     | Rapport de Preuve de Concept (POC)              |
| Zone d'étude         | Région Bretagne                                 |
| Sources de données   | data.gouv.fr · INSEE · Ministère de l'Intérieur |
| Année universitaire  | 2025 – 2026                                     |

### Introduction

La capacité à anticiper les comportements électoraux constitue un enjeu majeur pour les acteurs politiques, les institutions et les chercheurs en sciences sociales. Dans un contexte où le volume de données publiques disponibles n'a jamais été aussi important, l'exploitation de techniques avancées d'analyse de données et d'apprentissage automatique ouvre de nouvelles perspectives pour la compréhension et la prédiction des dynamiques électorales.

Ce rapport présente la Mise en Situation Professionnelle Reconstituée (MSPR) réalisée par le Groupe 4 dans le cadre de l'unité d'enseignement Big Data & Intelligence Artificielle du Master 1 Ingénierie Informatique à l'EPSI Paris. L'objectif de ce projet est de développer une Preuve de Concept (POC) d'un système d'analyse prédictive des tendances électorales à partir de données publiques ouvertes.

La région Bretagne a été choisie comme terrain d'expérimentation pour ses qualités intrinsèques : richesse et accessibilité des données publiques, diversité socio-économique et territoriale, stabilité démographique et comportements électoraux caractéristiques. Elle offre ainsi un cadre idéal pour valider l'approche méthodologique dans un périmètre contrôlé et représentatif.

La démarche adoptée repose sur une architecture de traitement de données complète : collecte de données multi-sources (data.gouv.fr, INSEE, ministère de l'Intérieur), mise en place d'un pipeline ETL (Extraction, Transformation, Chargement), construction d'un entrepôt de données relationnel, puis analyse exploratoire et modélisation prédictive par apprentissage automatique. L'ensemble de ces composants a été déployé dans une infrastructure conteneurisée sous Docker, garantissant la reproductibilité et la maintenabilité de la solution.

Ce document rend compte de l'intégralité de la démarche suivie, des choix techniques et méthodologiques effectués, des résultats obtenus et des perspectives d'évolution envisageables. Il est structuré selon les grandes étapes du projet : contexte et périmètre, sélection des critères, pipeline de traitement des données, modélisation conceptuelle, analyse exploratoire et modèles prédictifs testés.

## **1. Contexte du projet**

Dans le cadre de cette MSPR, une preuve de concept (POC) est réalisée afin de démontrer la fiabilité d'un système d'analyse prédictive des tendances électorales à partir de données publiques. Le projet s'appuie sur des sources issues de data.gouv.fr et de l'INSEE.

L'étude est menée sur la région Bretagne afin de valider l'approche méthodologique dans un périmètre expérimental. Ce rapport présente la démarche, les analyses effectuées et les résultats obtenus dans le cadre de cette preuve de concept.

## **2. Choix de la zone géographique**

### **2.1 Présentation de la zone**

La zone retenue pour la preuve de concept est la région Bretagne, située à l'ouest de la France et composée de quatre départements :

- Ille-et-Vilaine
- Finistère
- Morbihan
- Côtes-d'Armor

### **2.2 Justification du choix**

#### **A. Disponibilité et accessibilité des données**

La Bretagne dispose d'un volume important de données publiques exploitables, accessibles via data.gouv.fr et l'INSEE :

- Résultats électoraux historiques
- Statistiques INSEE
- Données de sécurité

- Données emploi / chômage
- Démographie
- Entreprises par secteur

## **B. Taille exploitable pour une preuve de concept**

La région est exploitable dans sa totalité, avec une population d'environ 3,4 millions d'habitants. Le découpage fin (communes, cantons) offre un volume raisonnable pour un POC : suffisamment de données pour entraîner un modèle, sans être trop volumineux pour une première expérimentation.

## **C. Représentativité socio-démographique**

La Bretagne présente une forte diversité territoriale :

### **Zones urbaines (Rennes, Brest)**

- Forte population étudiante
- Emplois tertiaires
- Activité numérique

### **Zones rurales**

- Agriculture dominante
- Vieillesse de la population
- Revenus plus faibles

Cette dualité permet de comparer les comportements électoraux urbains et ruraux.

## **D. Diversité économique**

Les secteurs économiques présents (agriculture, pêche, agroalimentaire, tourisme, numérique) génèrent des préoccupations économiques variées selon les territoires, ce qui produit un impact électoral mesurable.

## **E. Spécificités politiques régionales**

La Bretagne se caractérise par une tradition de vote modéré, des variations selon les scrutins et une montée récente de certains partis. Ce contexte en fait un terrain pertinent pour tester un modèle prédictif.

## **F. Stabilité démographique**

La région bénéficie d'une croissance démographique modérée et d'une attractivité résidentielle, permettant d'intégrer des variables comme l'arrivée de nouveaux habitants et l'évolution du tissu économique.

## 2.3 Limites identifiées

- Région moins dense que l'Île-de-France
- Moindre diversité ethnoculturelle
- Influence rurale forte pouvant biaiser certains modèles

### Synthèse

La région Bretagne a été retenue pour sa richesse en données publiques fiables, sa taille adaptée à un POC et sa diversité territoriale. Elle constitue un terrain pertinent pour tester un modèle prédictif reliant indicateurs socio-économiques et tendances électorales.

## 3. Justification du choix des critères

Dans le cadre de la preuve de concept réalisée sur la région Bretagne, plusieurs indicateurs socio-économiques et démographiques ont été analysés afin d'identifier les facteurs influençant les tendances électorales.

| Catégorie            | Indicateurs                                          |
|----------------------|------------------------------------------------------|
| Économie & emploi    | Taux de chômage, revenu médian, nombre d'entreprises |
| Contexte social      | Taux de pauvreté, taux de criminalité                |
| Résultats électoraux | Historique des scrutins (variable cible du modèle)   |

## 4. Démarche suivie et méthodes employées

La démarche repose sur l'exploitation de données publiques provenant de l'INSEE et de data.gouv.fr . Un pipeline ETL a été mis en place pour collecter, transformer et intégrer les données dans un entrepôt de données.


Ces données ont ensuite été analysées afin de développer un modèle prédictif appliqué à la région Bretagne. Les résultats sont présentés à travers des visualisations et des tableaux de bord décisionnels.

## Récapitulatif de la démarche

| 1. Collecte                                                     | 2. Transformation                                          | 3. Intégration                                                 | 4. Analyse & visualisation                     |
|-----------------------------------------------------------------|------------------------------------------------------------|----------------------------------------------------------------|------------------------------------------------|
| Extraction depuis data.gouv.fr, INSEE, Ministère de l'Intérieur | Nettoyage, normalisation, enrichissement des données (ETL) | Chargement dans l'entrepôt de données (architecture en étoile) | EDA, modélisation prédictive, tableaux de bord |

## Architecture data

Elle repose sur une chaîne de traitement de données complète. Les données électorales et socio-économiques sont d'abord collectées depuis des sources publiques puis stockées sur un espace S3. Dataiku assure les opérations d'ETL (nettoyage, transformation et intégration des données) avant leur chargement dans un entrepôt de données PostgreSQL. Les données consolidées sont ensuite exploitées dans Dataiku pour réaliser des analyses exploratoires (EDA), des visualisations et des modèles de machine learning. Enfin, les résultats sont restitués à travers des tableaux de bord et rapports interactifs dans Dataiku.



## Architecture réseaux plate-forme de déploiement


Cette architecture réseau est basée sur une approche de conteneurisation avec **Docker**, permettant de déployer et d'isoler les différents composants du projet dans des conteneurs indépendants. L'ensemble des services communique à travers un réseau Docker dédié nommé **mspr1**, qui assure la connectivité et les échanges de données entre les applications.

Le conteneur **MinIO** joue le rôle de stockage objet compatible S3. Il permet de centraliser les fichiers de données brutes provenant des sources publiques ainsi que les fichiers intermédiaires générés au cours des traitements. Cette couche de stockage garantit une conservation fiable et centralisée des données.

Le conteneur **Dataiku DSS** constitue le cœur de la plateforme décisionnelle. Il est chargé d'exécuter les processus ETL (Extraction, Transformation, Chargement), de préparer les données, de réaliser les analyses exploratoires (EDA), les visualisations ainsi que les modèles de Machine Learning. Dataiku agit comme un point central qui consomme les données provenant de MinIO et interagit avec l'entrepôt de données PostgreSQL.

Le conteneur **PostgreSQL** assure le rôle d'entrepôt de données (Data Warehouse). Il stocke les données nettoyées, transformées et enrichies produites par Dataiku. Cette base relationnelle permet de conserver un historique structuré des données et d'optimiser les requêtes analytiques.

Le flux de données suit ainsi un cycle complet : les données sont stockées dans MinIO, traitées et enrichies dans Dataiku, puis chargées dans PostgreSQL pour être exploitées dans les analyses, les tableaux de bord et les modèles prédictifs. Cette architecture modulaire présente l'avantage d'être facilement maintenable, évolutive et reproductible grâce à la conteneurisation Docker




## Présentation détaillé data et connexion différents serveurs

### Data Lake dans Minlo

### Data Lake dans Minlo

Il présente tous les buckets du projet organisé chacun en fonction de l'objectif à atteindre. Il sert également de source ETL dans le processus du pipeline ETL



## Connexion Minlo-Dataiku

Cette connexion est celle-là qui permet à dataiku de lire des objets dans Minlo et de les transformer. Le statut ok indique que les deux serveurs communiquent bien.

The screenshot shows the Dataiku DSS settings interface for an Amazon S3 connection. The header includes the Dataiku logo and 'DSS settings' with a 'License' link. The connection name is 'Amazon S3 connection: minio\_dataiku\_mspr1'. Below this is a 'Description' field. The 'Connection' section includes fields for 'Credentials' (set to 'AWS keypair'), 'Access key' (set to 'minioadmin'), 'Secret key' (masked with dots), and 'Region / Endpoint' (set to 'http://minio:9000'). A checkbox for 'Switch to bucket region' is present. The 'Snowflake fast loading/unloading' section contains fields for 'External stage name' and 'External stage path'. At the bottom, there are 'TEST' and 'SAVED' buttons. A green status bar at the bottom indicates 'Connection OK - Warning: missing default bucket for managed datasets'.

**Amazon S3 connection: minio\_dataiku\_mspr1**

Description

**Connection**

Credentials: AWS keypair

Access key: minioadmin

Secret key: .....

Region / Endpoint: http://minio:9000

Optional AWS region (e.g. eu-west-1) or custom endpoint (e.g. http[s]://my.s3.endpoint/)

Switch to bucket region: ☐ Switch to the bucket's region even if the region for connecting is set (to avoid redirects). Not applicable when the endpo

**Snowflake fast loading/unloading**

These optional settings are used for direct data loading from/unloading to Snowflake.

External stage name

If necessary, add double quotes for case sensitivity, and qualify the stage name with the database and schema

External stage path

Enter the path starting from and including the bucket. This should match the path used when creating the stage.

TEST SAVED

Connection OK - Warning: missing default bucket for managed datasets

## Lecture et chargement d'un fichier de Minlo dans dataiku

Ce processus nous permet d'accéder au contenu d'un bucket en définissant le chemin d'accès

S3 connection

minio\_dataiku\_mspr1

S3 Bucket

flowetl

✓

FETCH LIST

SELECT FROM LIST

Path in bucket

/

BROWSE...

Show Advanced options

TEST

Metastore catalog

Sync

Metastore database

Metastore table

flowetl / doc1

election\_presidentiel\_2012\_bretagne.csv

election\_presidentiel\_2012\_groupe\_par\_departement.csv

election\_presidentiel\_2012\_hors\_bretagne.csv

election\_presidentiel\_2017\_bretagne.csv

election\_presidentiel\_2017\_hors\_bretagne.csv


CANCEL

OK

## Transformation

Une fois la lecture/modification du data lake établies alors un ensemble de transformation s'effectue à chaque fois selon l'objectif à atteindre.

Exemple de flow dataiku nous permettant d'obtenir un fichier électoral transformé issu des datasets sources pour étudier les tendances électorales zone Bretagne et hors Bretagne





## Connexion dataiku-Postgresql et chargement de l'entrepôt de données

Notre entrepôt de données est sur une base relationnelle postgresql. Le dataset final issu de chaque processus de transformation est placé dans l'entrepôt de données de stockage relationnelle.

### Connexion dataiku-Postgresql

PostgreSQL connection: dataiku\_postgres\_mspr1 

Description

**Basic params**

Host

Database

Port

User

Password

Advanced JDBC properties [+ ADD PROPERTY](#)

Use custom JDBC URL ☐ Used to customize JDBC connection URL

**Advanced params**

Database version

 TEST  SAVED

Connection OK

### Chargement de l'entrepôt

**Input**

Search

- +  Dim\_socio\_2012
- +  Dim\_socio\_2017\_prepared
- +  Dim\_socio\_2017\_prepared\_prepared
- +  Dim\_socio\_2017sup
- +  doc1\_copy
- +  election\_presidentiel\_2012\_bretagne
- +  finaldataset\_prepared\_\_2\_
- +  finaldataset1
- +  mm
- +  nhr\_entrance\_rmar\_2017

**Settings**

Maintain strict schema equality

 RUN

**Output**

Add new dataset

Name

Store into

[CREATE DATASET](#)

NEW DATASET | USE EXISTING

## Lecture des tables dans l'entrepôt

```
Schema |                               List of relations
| Type | Owner |                               Name
-----+-----
public | FLOWETL_doc1_copy
| table | admin
public | FLOWETL_mm
| table | admin
public | FLOWETL_resultat_bretagne_2017_joined_prepared_prepared_stacke
| table | admin
3 rows)
```

| code_departement | code_commune | inscrits_sum | abstentions_sum | votants_sum | exprimes_sum | count |
|------------------|--------------|--------------|-----------------|-------------|--------------|-------|
| 22               | 22001        | 20154        | 5970            | 14184       | 13661        | 47    |
| 22               | 22002        | 38476        | 12637           | 25839       | 24673        | 46    |
| 22               | 22003        | 30501        | 11737           | 18764       | 17694        | 48    |
| 22               | 22004        | 178102       | 70242           | 107860      | 102656       | 171   |
| 22               | 22005        | 35097        | 11127           | 23970       | 22605        | 46    |
| 22               | 22006        | 7504         | 2434            | 5070        | 4799         | 46    |
| 22               | 22007        | 95825        | 33429           | 62396       | 60494        | 123   |
| 22               | 22008        | 40240        | 14428           | 25812       | 24406        | 47    |
| 22               | 22009        | 6301         | 2077            | 4224        | 4045         | 46    |
| 22               | 22011        | 34492        | 12438           | 22054       | 20980        | 47    |
| 22               | 22012        | 28723        | 9719            | 19004       | 17969        | 46    |
| 22               | 22013        | 77590        | 29259           | 48331       | 45804        | 135   |
| 22               | 22014        | 35851        | 12102           | 23749       | 22240        | 45    |

## 5. Modèle Conceptuel de Données (MCD)

Le MCD représente les principales entités du système d'analyse électorale ainsi que leurs relations. Il permet de structurer les données socio-économiques et électorales utilisées dans le projet.

### Entité centrale : ZONE

La table ZONE représente une commune ou une zone géographique étudiée. Elle contient les attributs suivants : code INSEE, nom de la commune, département, population et densité.




Figure 1 — Modèle Conceptuel de Données

La table ZONE constitue l'entité centrale du modèle, permettant de relier les résultats électoraux aux indicateurs socio-économiques, démographiques et sécuritaires via des clés étrangères.

### Garanties de cette structuration :

- Cohérence des données
- Historisation annuelle
- Exploitabilité analytique
- Compatibilité avec un entrepôt décisionnel


Le modèle adopté s'apparente à une architecture en étoile, optimisée pour les traitements décisionnels et les analyses prédictives.

## 6. Analyse Exploratoire des Données (EDA)

L'EDA (Exploratory Data Analysis) vise à explorer les jeux de données, détecter des corrélations, identifier des tendances et vérifier la qualité des données. Dans ce POC, elle analyse les relations entre les indicateurs socio-économiques et les résultats électoraux en Bretagne.


### 6.1 Types d'analyses réalisées

- **Analyse descriptive** : compréhension de la distribution des variables via des histogrammes et des boxplots (taux de chômage, revenu médian, taux de pauvreté etc.).




L'histogramme du taux de chômage met en évidence une concentration importante des communes autour d'un taux compris entre **8 % et 8,5 %**. Les valeurs les plus faibles et les plus élevées sont moins représentées.

Dans le cadre du projet, cette variable sera utilisée pour déterminer si les communes les plus touchées par le chômage présentent des comportements électoraux spécifiques et si elle possède un pouvoir prédictif sur les résultats futurs.



L'analyse montre une concentration des communes autour de valeurs comprises entre 10 % et 12 %, mais certaines communes présentent des niveaux de pauvreté plus élevés. Ces différences territoriales peuvent influencer les priorités des électeurs et donc les résultats des scrutins. Cette variable sera intégrée au modèle prédictif afin d'améliorer la capacité d'anticipation des résultats électoraux à court terme .

– **Analyse de corrélation** : identification des variables liées au vote via la matrice de corrélation de Pearson.



Vu de la matrice de corrélation, le revenu médian est la variable la plus influente dans notre jeu de données, suivie par le chômage, la pauvreté et le nombre d'entreprises. Ces indicateurs constituent donc les meilleurs candidats pour alimenter notre modèle de prédiction électorale.

## 6.2 Résultats et enseignements


Les visualisations produites (histogrammes, cartes, matrices de corrélation) ont permis de mettre en évidence des relations significatives, notamment, sur les scores électoraux.

Cette phase a également permis de vérifier la qualité des données, d'identifier les valeurs aberrantes et de sélectionner les variables les plus pertinentes pour la modélisation prédictive.

### Résultats obtenus par famille politique

#### Target classes

Proportions of classes computed on a sample using the current sampling settings



Le graphique montre la distribution des orientations politiques dominantes dans les communes étudiées.

- La **Gauche** est la famille politique la plus représentée avec **44 %** des communes.
- La **Droite** arrive en deuxième position avec **30 %**.
- Les catégories **Autre** (12 %) et **Centre** (10 %) occupent une place intermédiaire.
- L'**Extrême Droite** reste minoritaire avec seulement **4 %** des observations.


#### Interprétation

Cette répartition révèle une prédominance des sensibilités de gauche et de droite, qui représentent à elles seules **74 %** des communes analysées. Le paysage politique apparaît


donc principalement structuré autour de ces deux grands blocs, tandis que les autres tendances demeurent plus marginales.

## Analyse prédictive et algorithmme testés


### Random forest



### Logistic Regression



### Decision Tree



### Interprétations

| Modèle                | Score |
|-----------------------|-------|
| Régression Logistique | 0.756 |
| Random Forest         | 0.753 |
| Decision Tree         | 0.741 |

Les trois modèles obtiennent des performances relativement proches.

- La Régression Logistique est le meilleur modèle avec un score de 75,6 %.
- Le Random Forest arrive juste derrière avec 75,3 %.
- L'Arbre de Décision est légèrement moins performant avec 74,1 %.

Les résultats montrent que les données socio-économiques et électorales permettent d'expliquer une partie importante de l'orientation politique des communes.

## Modèle retenu

Le modèle retenu est :

Régression Logistique

Justification :

- meilleur score global ;
- modèle simple à interpréter ;
- temps d'entraînement faible ;
- bonne capacité de généralisation

## Conclusion

Les modèles de Machine Learning obtiennent des performances satisfaisantes, avec un score maximal de 75,6 %. Les résultats montrent que les variables socio-économiques, notamment le revenu médian, le taux de pauvreté et l'activité économique locale, constituent des facteurs explicatifs majeurs des orientations politiques observées dans les communes françaises. La régression logistique apparaît comme le modèle le plus performant et le plus interprétable pour cette étude.

| KPI               | Avant nettoyage | Après nettoyage |
|-------------------|-----------------|-----------------|
| Complétude        | 99,22 %         | 100 %           |
| Valeurs invalides | 0,78 %          | 0 %             |
| Valeurs uniques   | 270             | 96              |
| Doublons          | Présents        | Supprimés       |

Cohérence  
départementale

Non

Oui

Qualité globale

Bonne

Excellente